



**Universidade Presbiteriana Mackenzie**  
Faculdade de Computação e Informática

## **Projeto Aplicado IV**

# **Análise da Dinâmica do Emprego Formal no Brasil com Dados do Novo CAGED – Junho/2025**

BRENDA LOUIZE DE O. SOUSA CABRAL – RA 10424949

CRISTINA ALMEIDA DA SILVA – RA 10424207

ÉLIDA ROSA DE PAIVA SOUZA – RA 10424468

ISABEL CABRAL VIEIRA DE SOUSA – RA 1042479

# Problema Investigado

---

O Novo CAGED é a principal fonte de dados mensais sobre emprego formal no Brasil, mas apresenta desafios:

- Bases extensas, heterogêneas e distribuídas em múltiplas planilhas.
- Inconsistências de rótulos, cabeçalhos e padrões de séries.
- Estruturas diferentes por tabela (setorial, regional, temporal).
- Dificuldade de reproduzir análises completas e verificar coerência com o Sumário Executivo.

## Objetivos:

- Quantificar e comparar os saldos por setores, regiões e unidades da federação;
- Caracterizar o perfil dos vínculos criados (sexo, idade, escolaridade, faixa salarial);
- Produzir visualizações e relatórios replicáveis para acompanhamento mensal;
- Propor indicadores sintéticos (como “calor setorial-regional” e “saldo per capita municipal”);
- Documentar um fluxo de análise reproduzível, útil para gestores públicos e privados.

# Justificativa

---

- O emprego formal é indicador-chave da atividade econômica, renda e consumo.
- Junho/2025 registrou **+166.621 postos de trabalho**, sendo um mês estratégico para análises.
- Relevância social (ODS 8), econômica (monitoramento da retomada pós-pandemia) e institucional (subsídio para políticas públicas e planejamento privado).
- Necessidade de transformar bases administrativas em conhecimento replicável e verificável.

# Trabalhos Relacionados

---

**Clássicos de séries temporais:** Box & Jenkins (ARIMA), Holt–Winters, médias móveis

**Sazonalidade e decomposição:** STL (Cleveland et al., 1990)

**Forecasting aplicado:** Hyndman & Athanasopoulos (2018)

**Tendências recentes:** Modelos híbridos (ARIMA + LSTM), segundo IEEE Xplore (Li et al., 2021)

**Gaps identificados:**

- Ausência de pipelines reproduutíveis aplicados especificamente ao Novo CAGED.
- Pouca integração entre dados agregados e Sumário Executivo oficial.
- Falta de rotinas automatizadas para validação e análise visual estruturada.

# Solução Técnica Desenvolvida

---

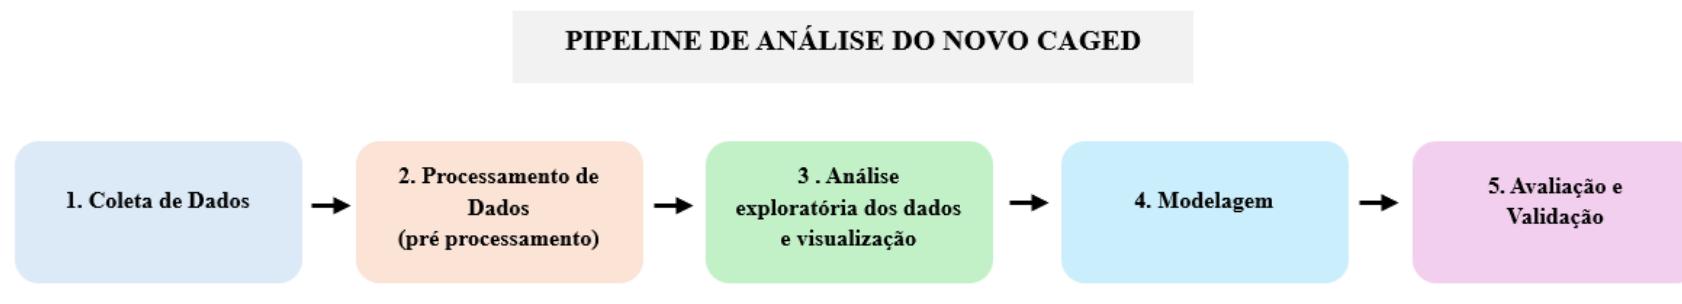


Figura 1 – Pipeline proposto para análise do Novo CAGED

Fonte: Elaboração própria (2025).

# Principais Técnicas Utilizadas

---

## Transformações e Pré-processamento

- Normalização via *string normalization*.
- Inferência de cabeçalhos (função `find_header_row`).
- Conversão automática wide → long.
- Verificação saldo = admissões – desligamentos.

## Transformações e Pré-processamento

- Normalização via *string normalization*.
- Inferência de cabeçalhos (função `find_header_row`)
- Conversão automática wide → long.
- Verificação saldo = admissões – desligamentos.

## EDA e Visualização

- Gráficos setoriais, regionais e UF
- Médias móveis de 3, 6 e 12 meses
- Decomposição STL
- ACF e PACF

# Resultados: Análises Setoriais



Principais achados:

Domínio do **setor de serviços**.

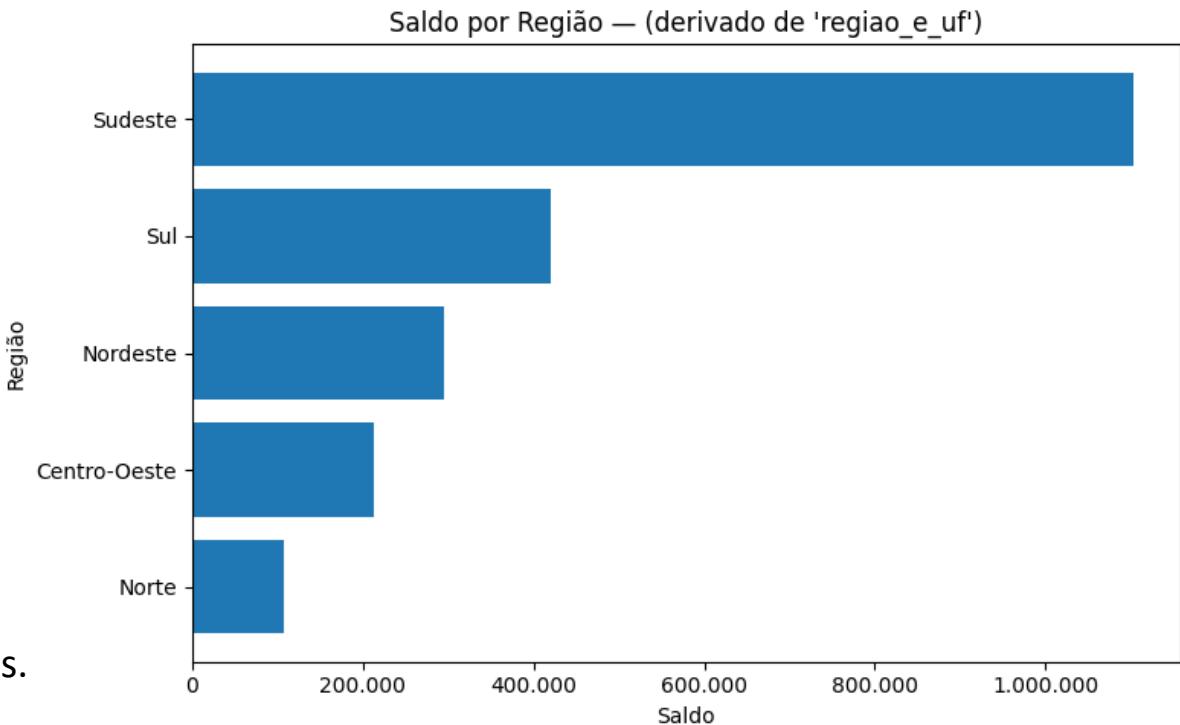
Destaques: Saúde, Administração Pública, Educação e Serviços Administrativos.

Indústria geral com saldo menor e menos dinâmico.

Agropecuária com sazonalidade forte e menor saldo no mês.

# Resultados: Análises Geográficas

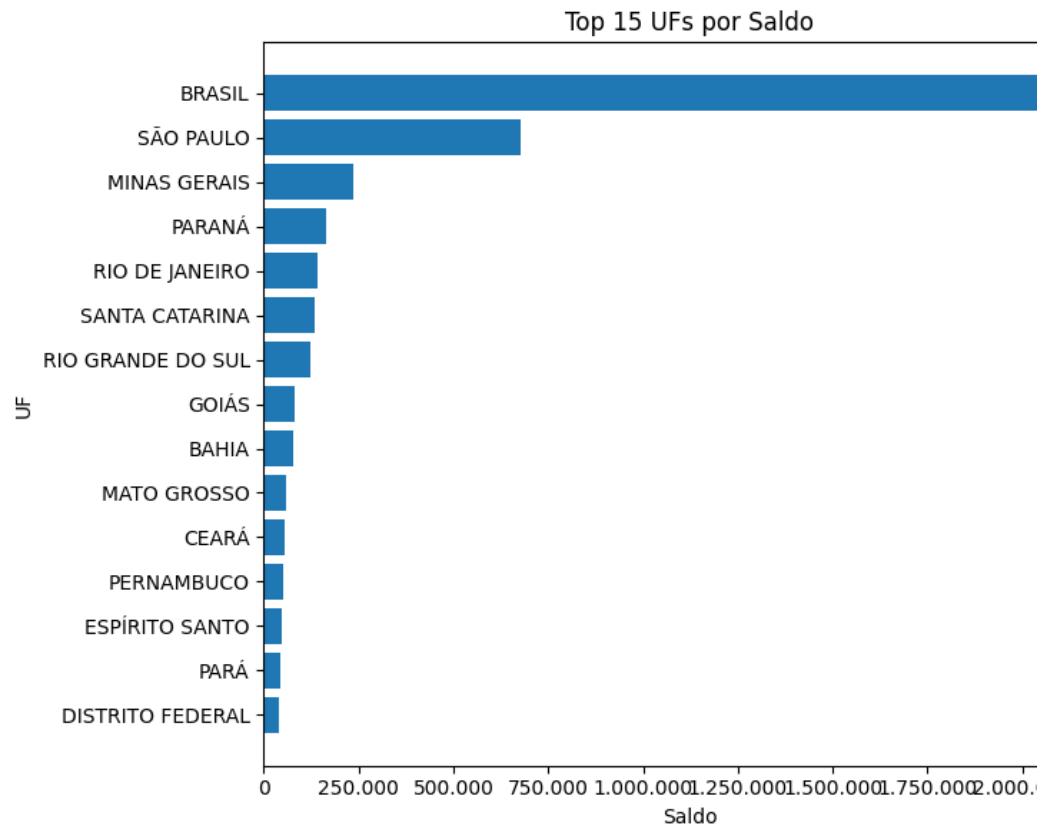
---



Sudeste e Sul concentram a maior parte dos empregos criados.  
Centro-Oeste impulsionado por agroindústria e capitais dinâmicas.  
Norte e Nordeste com menor dinamismo e maior volatilidade.

# Resultados: Análises Geográficas

---



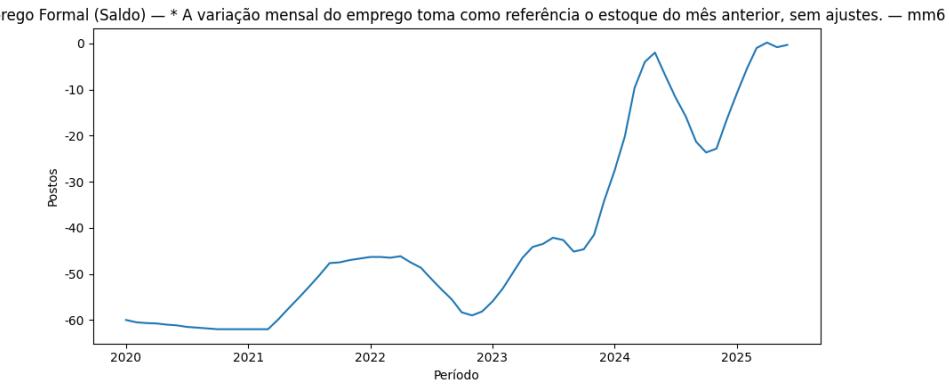
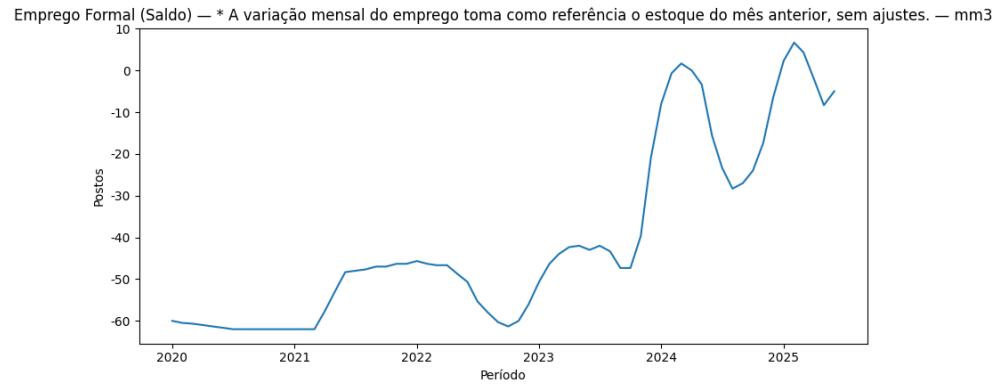
São Paulo lidera com margem ampla.

Santa Catarina, Paraná e Minas Gerais com saldos fortes e estáveis.

GO e MT crescendo via agroindústria.

Estados de menor porte aparecem na cauda da distribuição.

# Resultados: Séries Históricas (2020–2025)

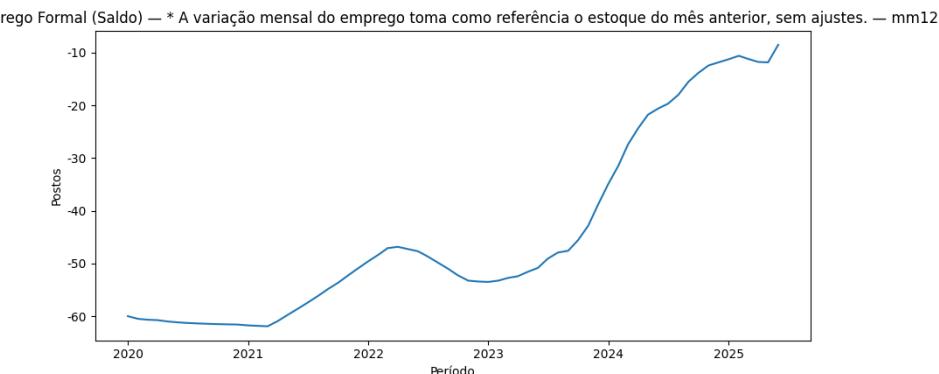


Queda drástica em 2020.

Recuperação entre 2021–2022.

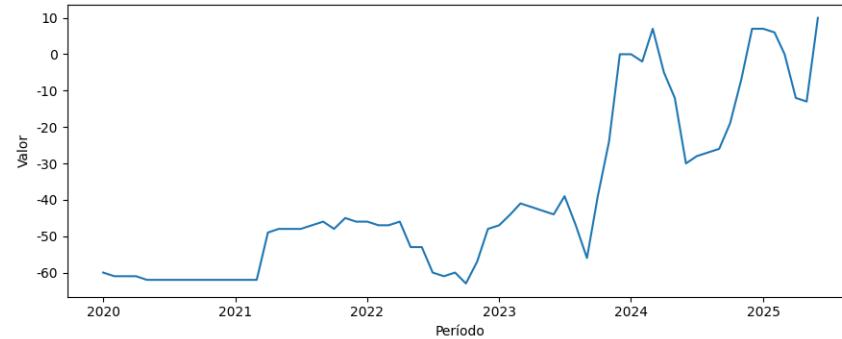
Estabilização e crescimento moderado 2023–2025.

As médias móveis revelam tendência ascendente e amortecimento da volatilidade.

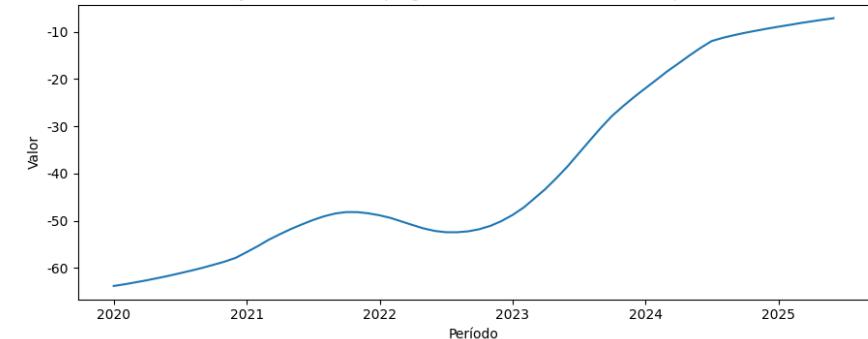


# Resultados: Decomposição STL

STL — Observado — \* A variação mensal do emprego toma como referência o estoque do mês anterior, sem ajustes.



STL — Tendência — \* A variação mensal do emprego toma como referência o estoque do mês anterior, sem ajustes.

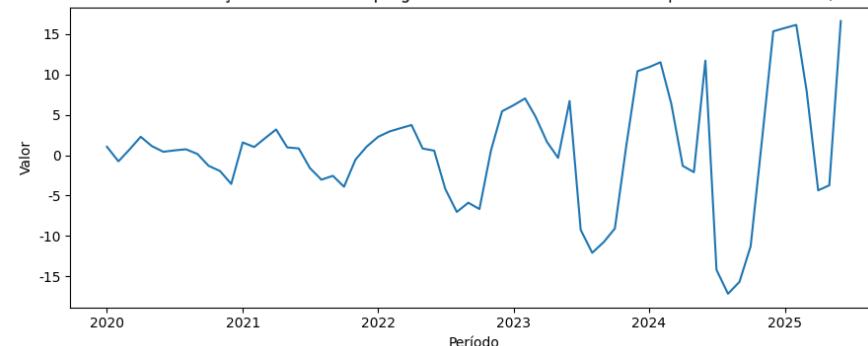


**Tendência** confirma recuperação sustentada após 2020.

**Sazonalidade** anual muito marcada (picos em dezembro; queda em jan–mar).

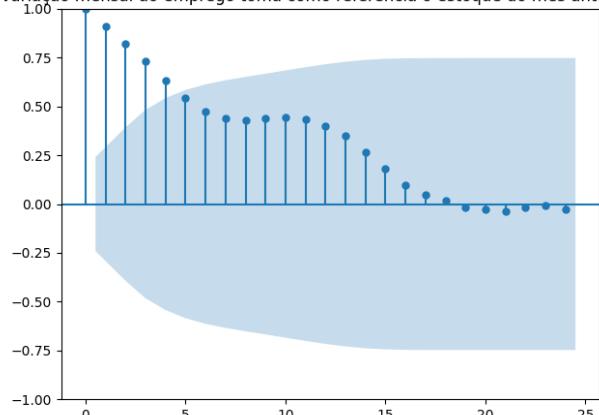
**Resíduo** compatível com choques episódicos (2020/2021).

STL — Sazonal — \* A variação mensal do emprego toma como referência o estoque do mês anterior, sem ajustes.

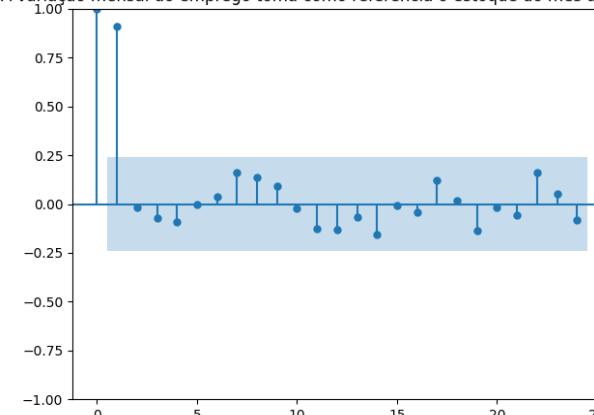


# Dependência Temporal

ACF — \* A variação mensal do emprego toma como referência o estoque do mês anterior, sem ajustes.



PACF — \* A variação mensal do emprego toma como referência o estoque do mês anterior, sem ajustes.



ACF revela lags de 12 meses → sazonalidade forte.  
PACF com poucos lags significativos → série parsimoniosa.  
Fundamenta uso de SARIMA sazonal.

# Modelagem: Performance Comparada

---

Treino: 60 meses | Teste: 6 meses

**Tabela 1 – Métricas dos modelos no conjunto de teste**

Modelo	MAE	RMSE	MAPE (%)
SARIMA $(2,1,0) \times (1,1,0)_{12}^{(1)}$	84.775	100.588	0,18
Holt-Winters (aditivo)	204.538	232.445	0,43
Naive	763.050	839.760	1,59
Sazonal Naive	1.649.342	1.650.559	3,44

**Conclusão:** O SARIMA foi superior em todas as métricas.

# Discussão dos Métodos

---

## **Diferenciais da solução técnica:**

Pipeline totalmente automatizada.

Detecção de cabeçalho e normalização robusta.

Conversão wide→long automatizada (passo crítico do CAGED).

Busca enxuta SARIMA com heurística de complexidade.

Integração entre Sumário Executivo (PDF) e Excel.

Geração de gráficos diagnósticos completos.

## **Desafios encontrados:**

Planilhas do CAGED são heterogêneas e pouco padronizadas.

Cabeçalhos variam entre tabelas; alguns contêm notas de rodapé.

Dificuldade em harmonizar UFs e agrupamentos de atividades.

Identificação de colunas mensais exige heurísticas de regex.

# Principais Resultados

---

- Recuperação estrutural do mercado de trabalho 2021–2024
- Serviços como motor da geração de empregos
- Desigualdade regional persistente (Sudeste/Sul x Norte/Nordeste)
- SARIMA mostra-se eficiente e confiável para previsão de curto prazo
- Previsões reproduzindo com precisão o valor oficial do saldo de junho/2025.

# Potenciais Melhorias

---

- Aplicar modelagem preditiva por **setor** e **UF**
- Incorporar microdados do eSocial
- Explorar modelos híbridos (ARIMA + LSTM/GRU)
- Criar dashboard interativo (Power BI / Streamlit)
- Automatizar ingestão mensal de dados.
- Implementar monitoramento contínuo (MLOps).

# Conclusões

---

O projeto demonstrou que, mesmo partindo de bases administrativas complexas, é possível construir um pipeline **robusto, reproduzível e validado** para análise e previsão do emprego formal.

A combinação de pré-processamento avançado, EDA detalhado e modelagem estatística clássica produziu um produto científico e técnico confiável, com potencial de aplicação em políticas públicas, análises econômicas, planejamento empresarial e monitoramento contínuo do mercado de trabalho brasileiro.